Direction Régionale : Casablanca – Settat *Cité des métiers et des compétences Nouaceur*

Contrôle continu N° 1 : Algorithmes distribués (M204)
Année 2026/2027

Filière : Intelligence Artificielle
Niveau : TS
Groupe : DIA_IAOBD_TS_201
Nom et Prénom :.....

Durée : 1H30MIN
Variante : B
Barème : .../20

Partie 1 : QCM (7.5 points – 1 point par question)

Q1. Un fichier de **500 Mo** est stocké dans HDFS. La taille de bloc est de **128 Mo** et le facteur de réplication est **2**. Combien de blocs physiques (copies comprises) sont stockés au total ? (1pt)

☐ 4 blocs

☐ 6 blocs

☐ 8 blocs

☐ 12 blocs

Q2. Un DataNode qui hébergeait des blocs tombe en panne. Le facteur de réplication est 3. Que fait HDFS pour ces blocs ? (1pt)

☐ Le fichier devient définitivement inaccessible sur HDFS.

☐ HDFS recopie les blocs manquants sur d'autres nœuds.

☐ Le client doit réécrire tout le fichier lui-même sans HDFS.

☐ Le cluster entier s'arrête jusqu'à la réparation.

Q3. Un utilisateur continue à consulter un service web alors qu'un des serveurs qui le fait tourner a été éteint, sans rien remarquer. Quelle propriété des systèmes distribués est illustrée ? (0.5pt)

☐ L'évolutivité : ajouter des serveurs au cluster

☐ La tolérance aux pannes : La continuité de service

☐ L'interopérabilité : dialoguer avec d'autres systèmes

☐ L'hétérogénéité : des machines de types différents

Q4. Un processus P1 envoie un message à un processus P2, qui le reçoit ensuite. Quelle relation existe entre l'envoi et la réception ? (1pt)

☐ Les deux événements sont concurrents, sans lien causal.

☐ La réception précède toujours l'envoi dans le temps.

☐ La réception dépend causalement de l'envoi préalable.

☐ Aucun lien n'existe, car les horloges sont différentes.

Q5. On exécute le Mapper WordCount sur la ligne `x y x x`. Quelle est sa sortie ? (1pt)

☐ `(x, 3)` et `(y, 1)` (deux paires seulement)

☐ `(x, 1)`, `(y, 1)`, `(x, 1)`, `(x, 1)` (quatre paires)

☐ `(x, [1,1,1])` puis `(y, [1])` (deux listes)

☐ `(y, x x x)` (une seule paire par mot)

Q6. Un job MapReduce utilise 3 Reducers. Quel composant décide quelle clé est envoyée à quel Reducer ? (0.5pt)

☐ Le Combiner, qui réduit les données sur chaque nœud

☐ Le Partitioner, qui route les clés vers les Reducers

☐ Le Mapper, qui émet des paires clé-valeur à partir des lignes

☐ Le NodeManager, qui exécute les conteneurs de tâches

Q7. Une base de données de 900 Go est coupée en 3 parties de 300 Go, chacune placée sur un serveur différent. Aucune partie n'est copiée ailleurs. Quel concept est appliqué ? (1pt)

☐ La réplication des données sur plusieurs serveurs

☐ Le sharding : partage des données entre serveurs

☐ Le heartbeat : signal périodique envoyé au maître

☐ Le load balancing : répartition des requêtes

Q8. Un serveur est tombé en panne. L'administrateur a déjà repéré l'absence de signal. Quelle étape du cycle de gestion des pannes est en cours ? (0.5pt)

☐ La détection : repérer l'absence de signal de vie

☐ Le diagnostic : trouver l'origine de la défaillance

☐ La récupération : reprendre le service ailleurs

☐ La réplication : copier les données ailleurs

Q9. Un cluster doit traiter davantage de données. L'administrateur ajoute de nouveaux workers plutôt que de remplacer le serveur existant par une machine plus puissante. Quel type de montée en charge réalise-t-il ? (1pt)

☐ Verticale : remplacer chaque serveur par une machine plus puissante

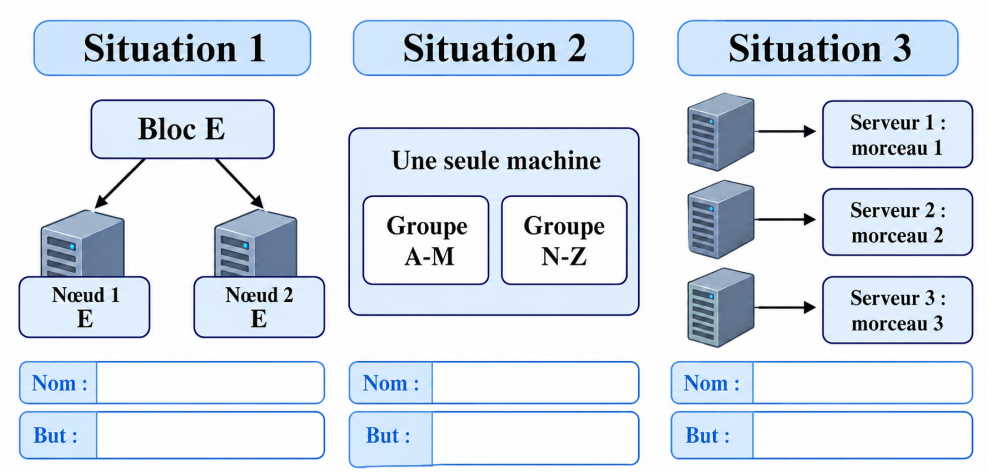
☐ Horizontale : ajouter de nouvelles machines au cluster existant

☐ Statique : figer la capacité du cluster dès son démarrage

☐ Circulaire : répartir les tâches en anneau entre les nœuds

Partie 2 : Lecture de schémas (6.5 points)

Q2.1 – Trois façons de répartir des données (1.5 points). Pour chaque situation, donnez le *nom du concept* puis son *but principal*, en une expression courte : 0,25 pt par nom et 0,25 pt par but, soit 1.5 pts.

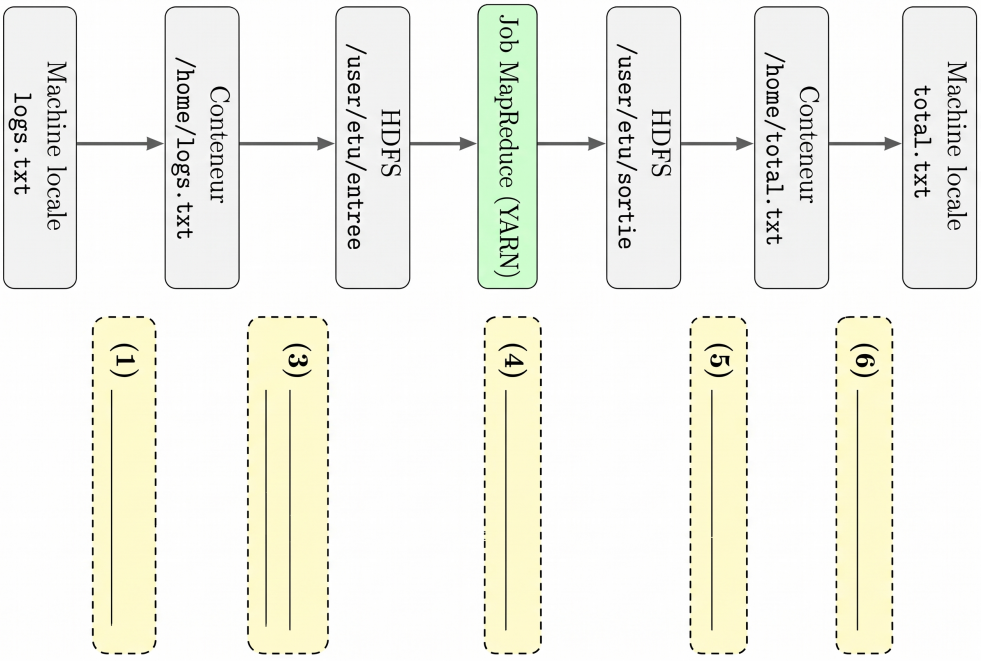


Q2.2 – Le trajet d'un fichier dans un job MapReduce (2.5 points, 0,5 pt par commande). Le fichier `logs.txt` part de votre machine, passe par le conteneur Docker, est traité par le cluster, puis revient sur votre machine sous le nom `total.txt`. Écrivez la commande correspondant à chaque flèche numérotée (1) à (5). La flèche (4) lance le job avec le code `map.py` et `reduce.py`.

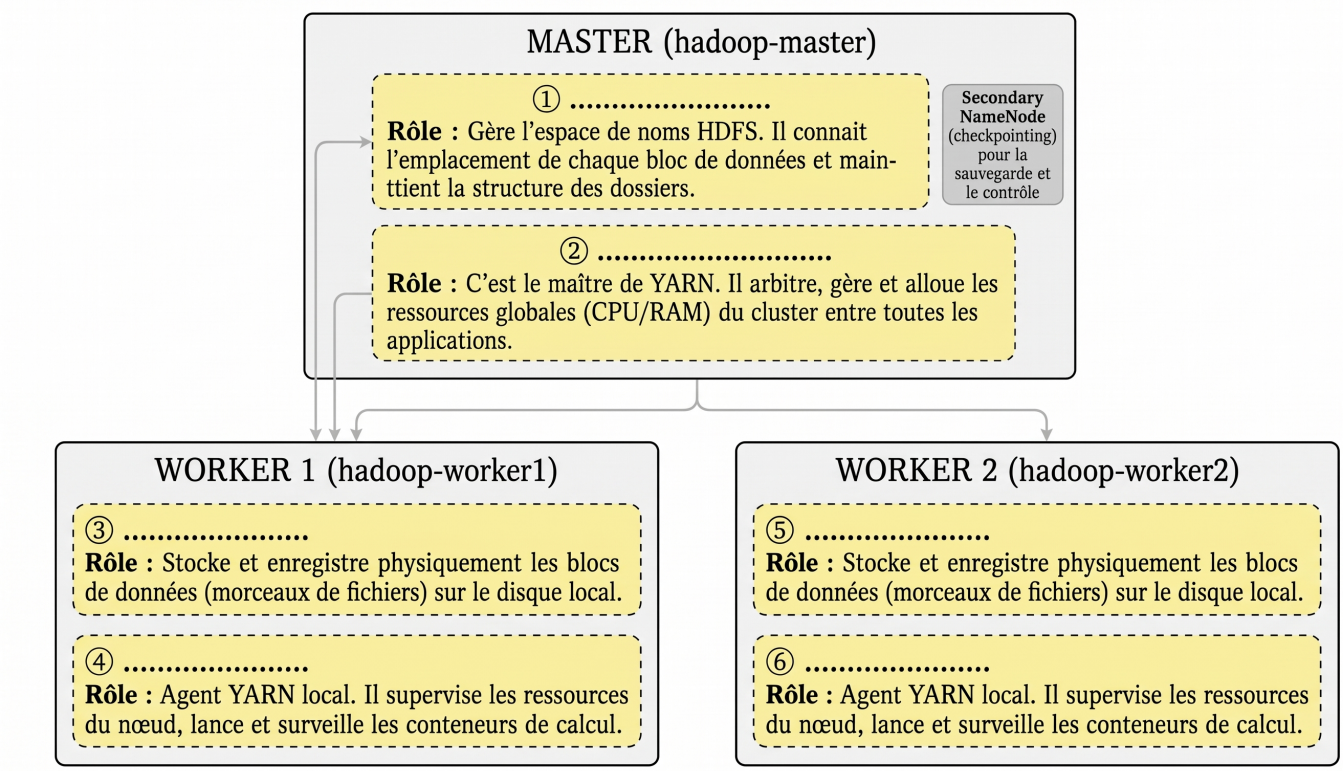
. . . . . .

. . . . . .

. . . . . .



Q2.3 – Qui fait quoi dans le cluster ? (1.5 points, 0,25 pt par case). Le cluster ci-dessous comporte un master et deux workers, configurés de la même manière. Chaque case jaune décrit le rôle d'un service. Écrivez le nom du service dans la case.



Question : si le worker 1 tombe en panne, quel service de ce worker est touché pour ses blocs de données, et pourquoi les fichiers restent-ils lisibles (1 pt)

.....

.....

.....

Partie 3 : Compréhension du Mapper et du Reducer (2 points)

Lisez attentivement les deux programmes Python suivants (`mapper.py` et `reducer.py`), utilisés dans Hadoop Streaming.

Q4.1 – `mapper.py` (1 point)

```python
#!/usr/bin/python3

import sys
from datetime import datetime

for line in sys.stdin:
    data = line.strip().split("\t")
    if len(data) == 6:
        date, time, store, item, cost, payment = data
        day = datetime.strptime(date, "%Y-%m-%d").weekday()
        print ("{0}\t{1}".format(day, cost))
```

*Quel est le rôle du programme `mapper.py` ? Expliquez en une seule phrase.

.....

Q4.2 – `reducer.py` (1 point)

```python
#!/usr/bin/python3

import sys

salesTotal = 0
oldDay = None

weekDays = ["Monday","Tuesday","Wednesday","Thursday","Friday","Saturday","Sunday"]

for line in sys.stdin:
    data_mapped = line.strip().split("\t")
    if len(data_mapped) != 2:
        # Something has gone wrong. Skip this line.
        continue

    thisDay, thisSale = data_mapped

    if oldDay and oldDay != thisDay:
        print (weekDays[int(oldDay)], "\t", salesTotal)
        oldDay = thisDay
        salesTotal = 0

    oldDay = thisDay
    salesTotal += float(thisSale)

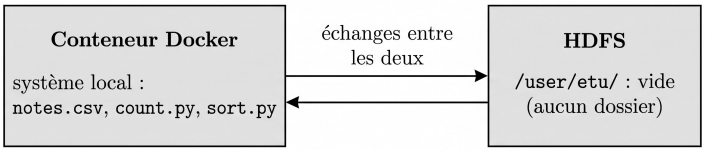
if oldDay != None:
    print (weekDays[int(oldDay)], "\t", salesTotal)
```

*Quel est le rôle du programme `reducer.py` ? Expliquez en une seule phrase.

.....

Partie 4 : Commandes HDFS (4 points)

Q3.1 – Six tâches sur le même cluster (3 points, 0,5 pt par commande). Voici l'état de départ : le fichier `notes.csv` et les scripts `count.py` sont dans le conteneur ; le dossier `/user/etu/` de HDFS est vide.



(1) Créer le dossier `/user/etu/entree` dans HDFS.

. . . . . .

(2) Afficher, en une seule commande, tout le contenu de `/user/etu` dans HDFS.

. . . . . .

(3) Copier `notes.csv` du conteneur dans `/user/etu/entree`.

. . . . . .

(4) Récupérer `/user/etu/sortie/part-00000` de HDFS et l'enregistrer dans `bilan.txt` du conteneur.

. . . . . .

(5) Rendre `count.py` exécutable dans le conteneur.

. . . . . .

(6) Donner les droits `750` au dossier `/user/etu/entree` et à son contenu, dans HDFS.

. . . . . .

Q3.2 – Vrai ou faux (1 points, 0,25 pt par affirmation). Cochez V ou F.

a) `hdfs dfs -put` écrase par défaut un fichier déjà présent dans HDFS sans l'option `-f`. **V** ☐ **F** ☐

b) `hdfs dfs -cut` copie un fichier depuis HDFS vers le système de fichiers local. **V** ☐ **F** ☐

c) `chmod 644 fichier` conserver les droits d'un fichier dans le système de fichiers local. **V** ☐ **F** ☐

d) `hadoop dfs` et `hdfs dfs` produisent des résultats différents sur le même cluster. **V** ☐ **F** ☐